4 相关工作

食物图像理解包含两个相互关联的目标：将可见内容转化为自然语言，以及将食材组成、份量与营养信息组织为膳食记录。围绕这两个目标，相关研究逐步形成了从视觉表示、序列生成到领域适配和质量评价的方法体系。本节沿四条研究主线梳理代表性进展，为 FoodLens 的自主模型实现与预训练模型适配提供依据。

4.1 食物图像描述生成研究

研究主线 视觉表示由全局向量走向空间 Token，信息交互由循环状态走向注意力与跨层融合。

4.1.1 从全局视觉表示到空间注意力

Show and Tell[1] 将视觉识别与语言生成统一为条件序列建模：预训练 CNN 提取全局图像向量，LSTM 根据图像条件与历史词语逐词生成描述，通过最大化参考句子的条件似然训练。图像在初始时间步输入，后续信息由循环状态传递。该工作在多个数据集上验证了 **CNN–RNN 编解码范式**，在其 MS COCO 开发集设置下取得 27.7 的 BLEU-4，为从图像到语言的端到端建模建立了清晰起点。

全局向量适合概括场景，食物描述则经常依赖分散的配料、颜色和形态。将整张图像压缩为单一表示，容易弱化多个局部对象及其细微属性。FoodLens 的 **ResNet-18 + GRU** 延续这一视觉编码与循环解码思路，以轻量骨干和门控循环单元构建自主基线；其设计重点是建立可解释的编码、条件注入和自回归生成流程。原始 Show and Tell 采用 LSTM，GRU 是课程项目对循环解码器的具体选择。

Show, Attend and Tell[2] 通过空间注意力将局部视觉信息引入逐词生成。模型保留 VGG-19 的 $14 \times 14 \times 512$ 特征网格，根据前一时刻的解码状态计算区域权重，形成动态视觉上下文。软注意力采用可微的区域加权和，硬注意力通过位置采样与随机梯度估计训练。二者都围绕“生成当前词语时关注哪些区域”建立视觉与语言的联系，注意力热图直观呈现这种对应关系。

该论文在 Flickr8k、Flickr30k 和 MS COCO 上验证了注意力机制，软、硬注意力在不同指标上各有优势。**双随机注意力正则项**鼓励句子生成过程覆盖不同区域，门控系数则调节视觉上下文的使用程度。空间选择缓解了全局压缩的信息瓶颈，也促使后续方法进一步研究区域之间的关系和不同层次视觉信息的组织方式。

4.1.2 Transformer 与网格特征建模

Transformer 图像描述模型通过**自注意力与交叉注意力**连接视觉表示和文本生成：视觉自注意力组织位置之间的关系，文本掩码自注意力建模历史词语，交叉注意力读取视觉上下文。网格特征将卷积特征图组织为视觉 Token，保留局部区域信息，再结合位置表示建模空间关联。训练时各词位置可在给定真实前缀的条件下并行计算，推理时采用自回归生成。

Meshed-Memory Transformer[3] 同时改进视觉编码和跨层解码。编码器引入可学习的持久记忆向量，解码器通过带门控的网状连接读取多个编码层，从而综合不同层次的区域关系。论文在 COCO Karpathy 划分及在线评测中报告了性能改进。该方法主要采用检测区域特征，其“网状”结构指编码层与解码层之间的连接，为利用多层视觉信息提供了代表性思路。

S^2 Transformer[4] 将这一问题推进到网格特征的空间与层次建模。其空间感知伪监督模块（Spatial-aware Pseudo-supervised，**SP**）学习聚类中心，对网格进行软分配，并聚合相对于中心的残差，形成伪区域特征。原始网格与伪区域由共享参数的编码器处理，在局部覆盖和聚合语义之间形成互补，整个过程使用可学习聚类而无需额外区域标注。

其尺度增强模块（Scale-wise/Scale-aware Reinforcement，**SR**）拼接不同编码层的输出，经映射与加权残差补充最高层表示，再融合两个分支供解码器使用。SR 的作用是跨层特征融合，序列级奖励训练由独立的训练阶段完成。论文采用来自预训练检测器的 $7 \times 7 \times 2048$ 网格输入。在相同 ResNeXt-101 特征、MS COCO Karpathy 测试划分及论文两阶段训练协议下，加入 SP 和 SR 后，CIDEr 由 131.2 提升至 133.5，表列参数量由 33.57M 增至 34.64M，展示了空间聚合与层次融合的收益。

图 1 展示 S^2 的实际网络：左侧网格与右侧伪区域经过共享编码，底部 SP 完成空间聚合，两侧 SR 将多层信息补充到解码表示。表 1 进一步比较各方法的技术重点。FoodLens 据此设置**全局特征 + GRU** 与**空间网格 + Transformer** 两种自主模型，考察局部信息与注意力建模对食物描述的影响。S^2 为网格模型提供设计依据，M^2 提供多层信息利用的参照；项目比较时结合视觉表示和解码结构两个变化解释结果。

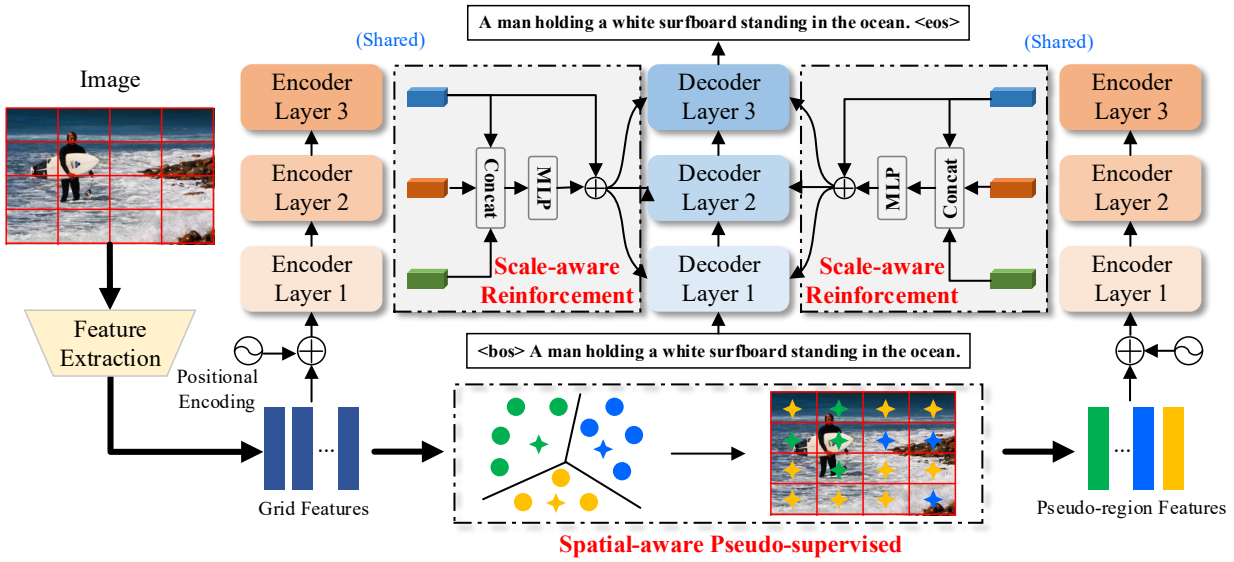


图 1 S^2 Transformer 的网格与伪区域双分支架构。引自 Zeng 等 [4] 原图 2（IJCAI），裁去页面正文，保留原图连接。SP 聚合网格，SR 融合编码层。

表 1 图像描述模型的表示与生成方式比较

方法	视觉表示	解码与交互	技术特点
Show and Tell	CNN 全局向量	LSTM 循环生成	简洁的条件序列基线
Show, Attend and Tell	CNN 空间网格	注意力 + LSTM	逐词选择视觉区域
M^2 Transformer	检测区域、多层编码	记忆增强、网状跨层解码	综合多层区域关系
S^2 Transformer	原始网格、SP 伪区域	共享编码、SR 融合	空间聚合与层次互补

4.1.3 细粒度食物描述与领域适配

Food-500 Cap[5] 将图像描述评价推进到细粒度食物领域。研究从 ISIA Food-500 的 494 个类别中各选择 50 张图像，共构建 24,700 个图文样本。每张图像对应一条人工描述，覆盖菜品名称、可见食材、颜色、形状和容器，并为类别补充饮食文化来源标签。这类标注将“识别菜品”扩展为“描述区分菜品的可见细节”，与 FoodLens 的任务一直接对应。

该研究以分类、检索、描述和图像合成四种零样本任务探测九种视觉语言模型。描述评价使用 BLEU、METEOR、ROUGE、CIDEr、CLIPScore，以及检查类别名称的**语义标签准确率**。实验揭示了食物属性遗漏、误识别和不同饮食文化类别的表现差异，说明领域适配与细粒度分析具有实际价值。每图单参考对合理改写的覆盖有限，类别名称匹配侧重菜品识别；FoodLens 因而结合自动指标与食材、属性错误分析评价描述质量，重量和营养标签则由结构化膳食任务提供。

4.2 食物理解与结构化营养估计研究

研究主线 食材集合回答“有什么”，重量与营养估计回答“有多少”；定量预测依赖可靠的份量监督。

4.2.1 食材集合识别与依赖关系

Inverse Cooking[6] 以“图像理解—食材预测—食谱生成”组织食物语义推断。模型先从图像预测食材集合，再让步骤解码器同时关注图像特征和食材嵌入。食材预测器利用 Transformer 的自回归过程学习共现关系，以跨时间最大池化后的集合损失减少输出排列的影响，并处理结束标记与集合基数。这种**依赖建模与集合监督**兼顾了食材间联系和标签的无序性。

在筛选后的 Recipe1M 数据上，论文使用 1,488 项食材词表，测试集全局食材 IoU 和 F1 分别达到 32.11 和 48.61。图像与食材共同生成步骤时，测试困惑度为 8.51，优于仅图像条件的 9.66 和仅食材条件的 8.67，验证了**视觉信息与显式食材语义的互补性**。该研究的输出是食材集合与食谱，隐藏配料和中间识别错误构成主要困难；将其思想用于膳食记录时，逐食材重量及营养值需要相应的定量标签。

图 2 给出了这一路线的网络结构。食材预测器位于图像编码器与食材编码器之间，步骤解码器接收图像和食材两路表示，将食材识别与语言生成连接起来。

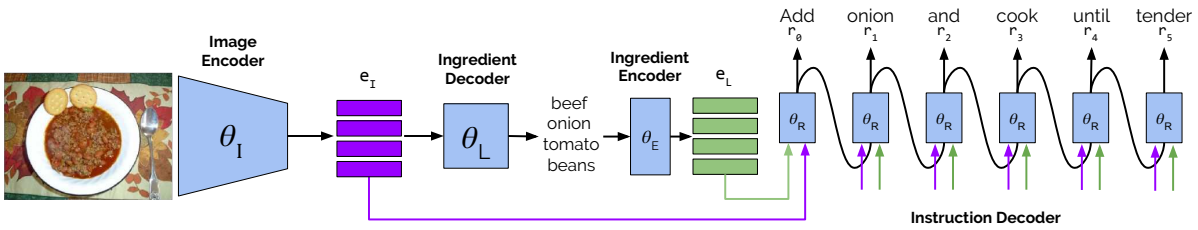


图 2 Inverse Cooking 的图像、食材与步骤生成网络。引自 Salvador 等 [6] 原图 2（CVF），仅裁去页面正文；紫色与绿色连接分别传递图像和食材信息。

4.2.2 份量监督与重量、营养估计

Nutrition5k[7] 通过物理测量建立了视觉营养理解的数据基础。论文表 1 列出 5,066 份餐食，涉及超过 250 种食材，约有 20,000 段侧视视频，其中约 3,500 份具有俯视 RGB-D

数据。采集时逐项添加食材或已知配方的成品食物，记录重量增量并扫描；四台侧面摄像机各扫过约 90°，共同覆盖餐盘周围视角，俯视 RealSense 提供颜色与深度。

增量秤量、配方分解与营养数据库共同构成标签依据：成品项的食材比例由配方分解，营养值结合食材重量和 USDA 数据库计算。同一餐盘的增量扫描被放入同一数据子集，保持训练与测试之间的餐盘独立性。

Nutrition5k 的主要基线采用 **InceptionV2 多任务回归**，通过共享视觉特征和任务分支预测热量、宏量营养素以及需要时的总重量，训练与评价主要使用 MAE。论文区分了**每克营养密度**与**整餐绝对值**：前者按真实重量归一化标签，并在表中借助真实重量换算为整餐数值；后者直接从 RGB 预测总量，同时承担组成识别与份量估计。数据提供食材级重量，主要回归基线关注整餐级输出。

图 3 展示共享骨干与多个回归头的连接方式。与图 2 的食材条件生成相比，这一架构将视觉表示直接映射为重量及营养数值，训练监督也相应转向物理测量和数据库标签。

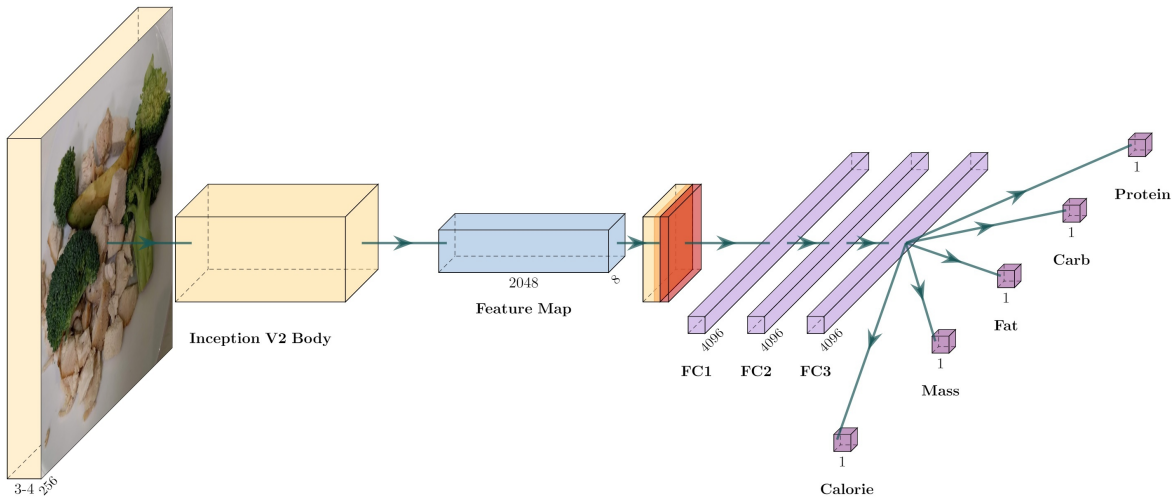


图 3 Nutrition5k 的多任务回归网络。引自 Thames 等 [7] 原图 6（CC BY 4.0）。InceptionV2 后的两层 FC 共享参数，随后以独立分支预测蛋白质、碳水、脂肪、总重量和热量。

深度信息进一步改善了份量估计。一种设置将深度作为额外通道与 RGB 联合输入；另一种设置根据相机几何和食物前景估计体积，将体积标量与 RGB 特征结合，用独立的 **InceptionV3 重量网络**预测总重量，再与每克营养密度组合。在论文表 4 的俯视重量回归实验中，图像输入基线 MAE 为 38.1 g，加入体积后降至 29.4 g，显示了几何信息对份量预测的价值。该比较对应相同的重量任务，RGB-D 研究则使用具备深度的子集。

食材组成、份量和营养密度共同决定整餐营养。单张 RGB 图像的主要困难在于尺度缺失、遮挡，以及油脂和调味料等不可见成分；Nutrition5k 集中的采集地点与视角也使跨场景推广成为重要问题。FoodLens 采用课程 RGB 数据，以**食材 F1、重量与营养 MSE、JSON/Schema 有效率**分别衡量语义、定量和结构质量。这一分层评价将两条研究路线的目标落实到同一膳食记录中，并保留各自明确的检验依据。

4.3 多模态预训练与参数高效微调

研究主线 预训练模型提供图文理解基础，低秩适配与量化分别压缩任务更新规模和基础权重存储。

4.3.1 视觉语言基础模型的领域适配

Qwen3-VL[8] 采用视觉编码器、视觉语言映射模块与 Qwen3 语言模型组成的架构，提供 2B、4B、8B、32B 等稠密模型。其 **DeepStack** 将多个视觉编码层的特征经专门映射注入语言模型前几层，加强不同层次视觉信息的利用；交错 MRoPE 改进时空位置表示，视频时间戳提供显式时序信息。分阶段预训练与后训练进一步形成多种视觉指令的处理能力。

报告通过视觉问答、文字识别、空间理解和多模态推理基准展示通用能力，并以消融实验支持多层融合的作用。FoodLens 选择 Qwen3-VL 的依据是**图文理解与指令适配能力**：通过领域样本学习膳食字段和 JSON 输出形式，衔接通用预训练与课程任务。食物重量与营养回归属于领域目标，实际效果由课程数据上的微调前后对照检验。

图 4 呈现基础模型的实际架构：视觉编码器形成视觉 Token，语言模型处理图文序列，右侧 DeepStack 将多个视觉层的特征注入语言模型的早期层。

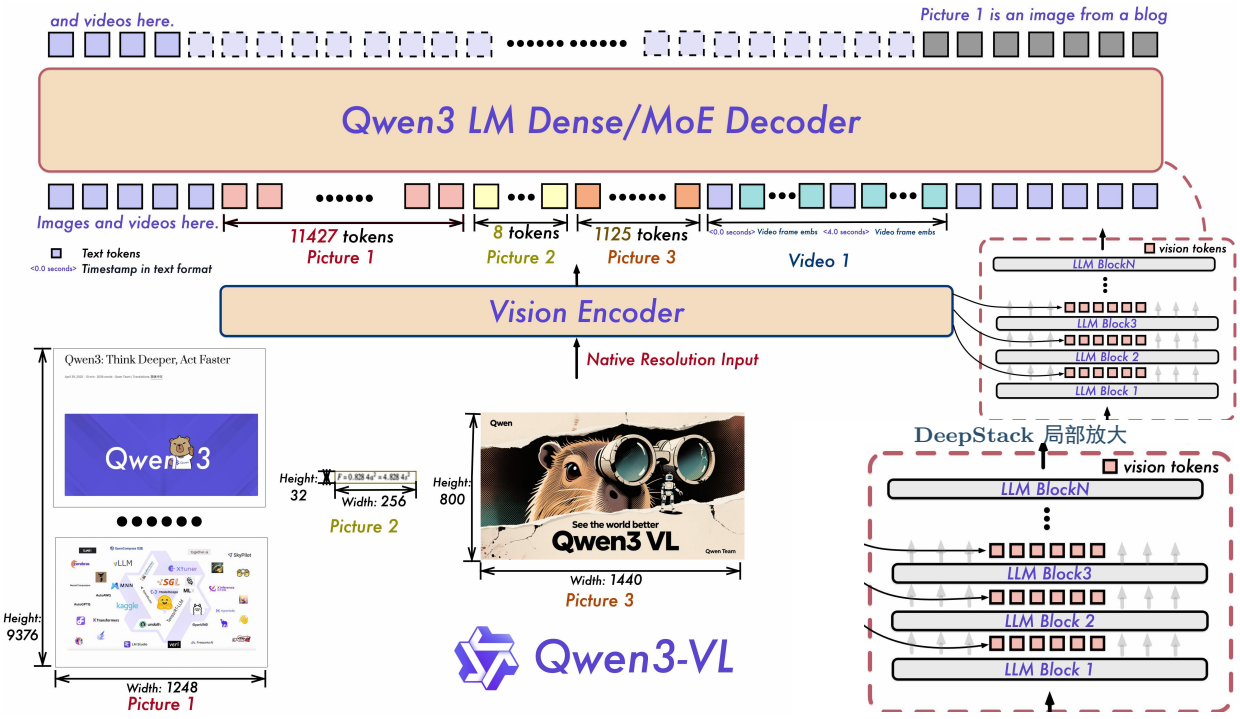


图 4 Qwen3-VL 的多模态基础架构。引自 Bai 等（Qwen Team）[8] 技术报告 v2 原图 1；右下视频输入示例替换为 DeepStack 局部放大，主体网络与连接保持原样。

4.3.2 低秩更新与量化存储

LoRA[9] 将任务适配表示为冻结基础权重上的低秩增量。对 $W_0 \in \mathbb{R}^{d\times k}$，其更新形式为

$$W = W_0 + \frac{\alpha}{r} BA, \qquad B \in \mathbb{R}^{d\times r}, \quad A \in \mathbb{R}^{r\times k}, \quad r \ll \min(d,k). \tag{1}$$

可训练参数由 dk 降为 $r(d+k)$，其中 r 控制适配容量，α 调节更新尺度。原论文在多种语言模型任务上获得与全量微调相当或更好的效果，并减少参数、优化器状态及训练显存开销。低秩更新可合入基础权重，便于保存与切换任务适配结果；秩与注入模块共同决定更新范围。

QLoRA[10] 在低秩适配基础上，以 4 位形式存储冻结权重，通过反量化参与较高精度计算，将梯度传递给适配器。**NF4、双重量化与分页优化器**分别优化权重表示、量化常数存储和显存峰值。论文在特定语言模型配置下实现了单张 48 GB GPU 适配 65B 模型，并在多项实验中接近 16 位适配效果；其 33B、65B 与全量 16 位微调的效果比较仍受资源限制。

图 5 从基础模型、适配器和优化器状态三个层面比较微调成本。**LoRA 减少训练更新，QLoRA 进一步压缩基础权重**，共同服务于有限算力下的领域适配。多模态训练的实际成本还取决于视觉 Token 数量、序列长度、模块选择与量化算子兼容性。FoodLens 因而同时记录显存、耗时和任务质量，以食材 F1、数值 MSE 与 Schema 有效率评价微调收益，形成资源效率与领域效果之间的对照。

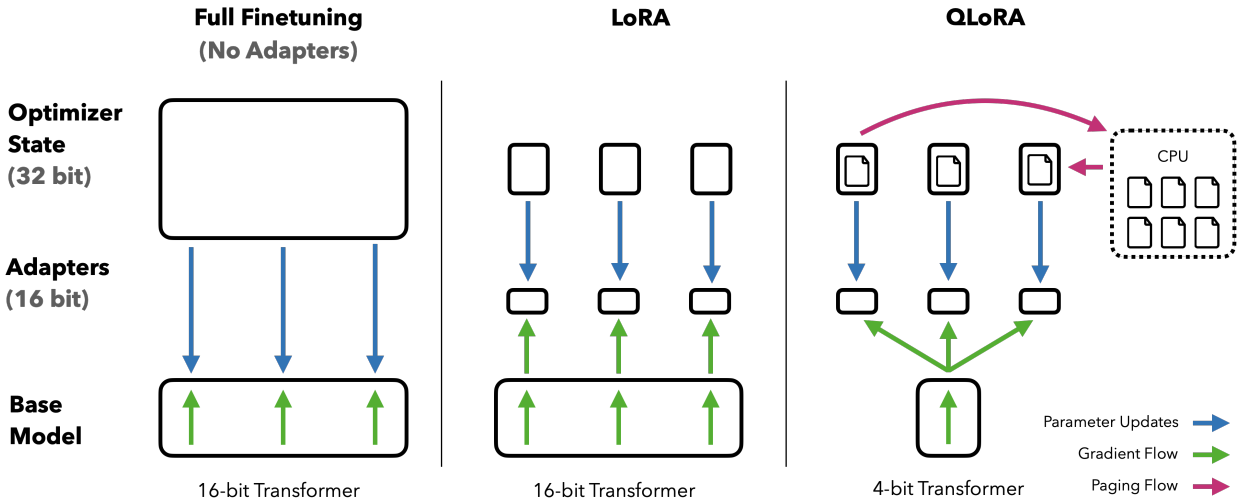


图 5 全量微调、LoRA 与 QLoRA 的参数更新和存储机制。引自 Dettmers 等 [10] 原图 1（CC BY 4.0）。QLoRA 冻结 4 位基础权重，以分页优化器缓解显存峰值。

4.4 生成模型的训练优化与评价

研究主线 训练优化改变模型参数，质量评价检验输出；序列奖励将两者连接起来。

4.4.1 从逐词似然到序列级优化

交叉熵训练逐词拟合参考描述，最终指标则对整句评分；Teacher Forcing 与推理使用自身前缀之间也存在条件差异。**SCST**[11] 采用策略梯度，将采样描述的奖励与模型自身推理解码结果的奖励之差作为优势信号。经典实现以贪心解码为基线，强化优于当前推理结果的序列，直接优化 CIDEr 等不可微指标并降低估计方差。论文在 MS COCO 上验证了这一序列级优化策略。

CIDEr 等指标既可报告质量，也可作为 SCST 奖励，前者用于比较输出，后者参与参数更新。FoodLens 的任选实验比较交叉熵与 SCST，同时观察描述指标、食材细节和幻觉变化，以分析序列奖励带来的实际收益。

4.4.2 从图文一致性到结构化解释

CLIPScore[12] 用预训练 CLIP 编码图像与候选描述，对归一化表征的余弦相似度进行截断和缩放，形成无需参考文本的图文相容性分数。论文在 Flickr8k、COMPOSITE 等人工判断数据上验证了相关性，并提出结合参考文本的 RefCLIPScore。整体语义匹配为 BLEU、CIDEr 等文本指标补充了直接的视觉依据。

FLEUR[13] 将图像、候选描述和评分标准输入 LLaVA，通过追加提示解释分数。其分数平滑使用小数位数字 Token 的概率计算加权期望，缓解离散打分中的大量并列。该方法在 Flickr8k-CF、COMPOSITE、Pascal-50S 等设置中表现出较好的人工判断一致性，将无参考评价扩展为**可阅读的评分依据**；概率平滑依赖可访问的模型输出概率。

EXPERT[14] 进一步以流畅性、相关性、描述充分性组织解释，在人工评分数据基础上构建解释监督，并以先评分、后解释的模板微调视觉语言模型。它分别检验评分相关性和解释的一致性、事实性、信息量，实验支持**统一标准与解释监督的结合**能够改善解释质量。其在多数无参考基准上取得较好结果，Pascal-50S 部分设置由其他方法领先；原文误差分析还指出了对细节缺失惩罚过重的情形。

表 2 归纳了各方法的角色。多模态评价的共同挑战是视觉判断偏差、解释可靠性和推理成本。FoodLens 的 VLM-as-Judge 参考 FLEUR 的视觉条件评分与 EXPERT 的结构化解释，通过人工样本检查食材误判、遗漏和幻觉，形成与传统自动指标互补的分析。**食材识别与营养数值**分别由任务指标检验，使语言质量、视觉事实和定量误差各有依据。

表 2 训练优化与无参考评价方法的角色比较

方法	方法类别	主要用途	FoodLens 对应任务
SCST	序列级训练优化	用奖励差更新生成策略	任选：描述模型继续训练
CLIPScore	图文相似度评价	衡量整体语义相容性	描述质量的补充指标
FLEUR	多模态无参考评价	概率平滑评分、自然语言解释	任选：视觉评分与错误解释
EXPERT	监督适配的无参考评价	标准化、多维度解释	任选：结构化评价与人评校准

4.5 本章小结

图像描述研究沿着**全局表示—空间选择—视觉关系与跨层融合**发展，Food-500 Cap 将这些方法的检验落到菜品和可见属性。结构化膳食研究进一步揭示了食材语义、份量监督与营养密度之间的联系。单图尺度和不可见成分是定量预测的核心困难，领域差异与评价偏差则贯穿模型迁移和结果分析。

FoodLens 的技术选择由此形成清晰对应：以 **ResNet-18 + GRU**、**ResNet Grid + Transformer** 比较视觉表示与生成方式，以 Qwen3-VL + LoRA/QLoRA 研究结构化膳食适配，以 SCST 检验序列优化收益，以 VLM-as-Judge 增强评价解释。项目围绕自主实现、预训练适配与对照分析展开，分别检验描述、食材、数值与结构质量，体现对相关方法的理解及其在课程条件下的工程实现能力。

5 技术方案

5.1 系统总体架构

FoodLens 将单张食物 RGB 图像映射为自然语言描述和结构化膳食记录。系统以两种自主描述模型建立可解释的对照，再将其中的视觉与序列模块迁移到食材生成和重量回归；预训练视觉语言模型提供独立的领域适配对照。图 6 给出模块复用及评价关系。全部模型在推理时仅接收图像与固定任务指令，标签及含答案的元数据只用于监督和离线评价。

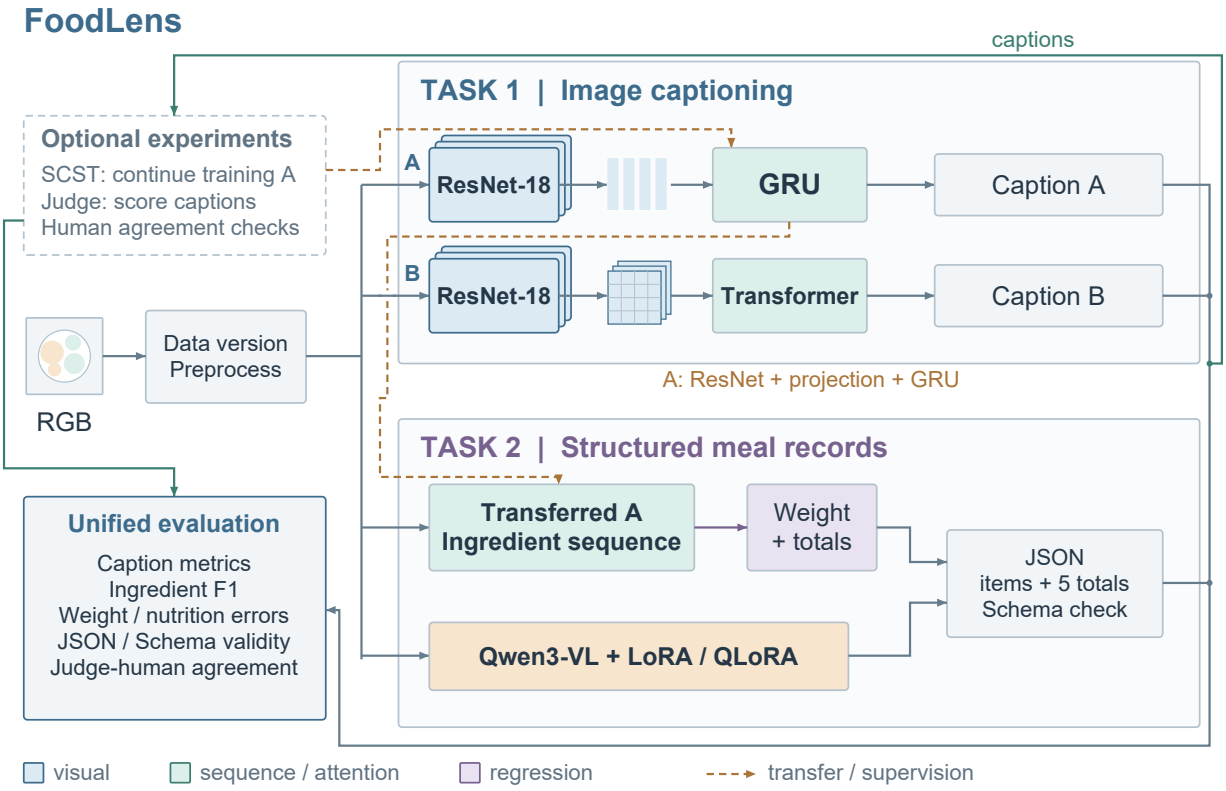


图 6 FoodLens 总体架构。实线表示数据流，虚线表示参数迁移或离线监督关系；两项任选实验复用描述模型及其输出。

共享数据层负责图文匹配、固定划分、文本编码和批处理，评价层接收按样本 ID 保存的预测文件，统一计算指标。任务一输出 Caption；任务二自主模型输出食材名称序列、对应重量与五维整餐数值，经确定性程序组装 JSON。Qwen3-VL 直接生成 JSON 文本，两条路线共用解析、Schema 校验与数值评价程序。该组织方式将模型能力与输出格式处理分开，便于追踪食材识别、定量估计和结构错误。

5.2 食物图像描述生成模型设计

共享输入与文本表示。两种自主模型均输入 224×224 RGB 图像，使用 ImageNet 预训练 ResNet-18 的 `layer4` 输出 $F \in \mathbb{R}^{512\times7\times7}$，移除分类层[1]。验证、测试采用短边缩放至 256 后中心裁剪，训练仅增加水平翻转，沿用预训练均值与标准差。两模型共享仅由训练 Caption 拟合的英文词级词表和规范化规则，保留标点，设置 `PAD/BOS/EOS/UNK`；最大生成长度初设为 64 Token，截断比例在训练前检查。以下维度和超参数均为起始配置，由验证集调整。

模型 A：全局视觉条件的 GRU。令 $v = \mathrm{GAP}(F) \in \mathbb{R}^{512}$，投影为 $z = \tanh(W_v v + b_v) \in \mathbb{R}^{256}$。采用 256 维词嵌入、单层 256 维 GRU，将 z 同时作为初始隐藏状态和每步输入条件：

$$h_0 = z, \quad h_t = \mathrm{GRU}([E(y_{t-1}); z], h_{t-1}), \quad p_\theta(y_t \mid y_{<t}, I) = \mathrm{softmax}(W_o h_t + b_o). \tag{2}$$

全局向量持续参与解码，降低长序列中视觉条件衰减的影响；输入拼接后的维度固定为 512，便于任务二直接复用 GRU 权重。

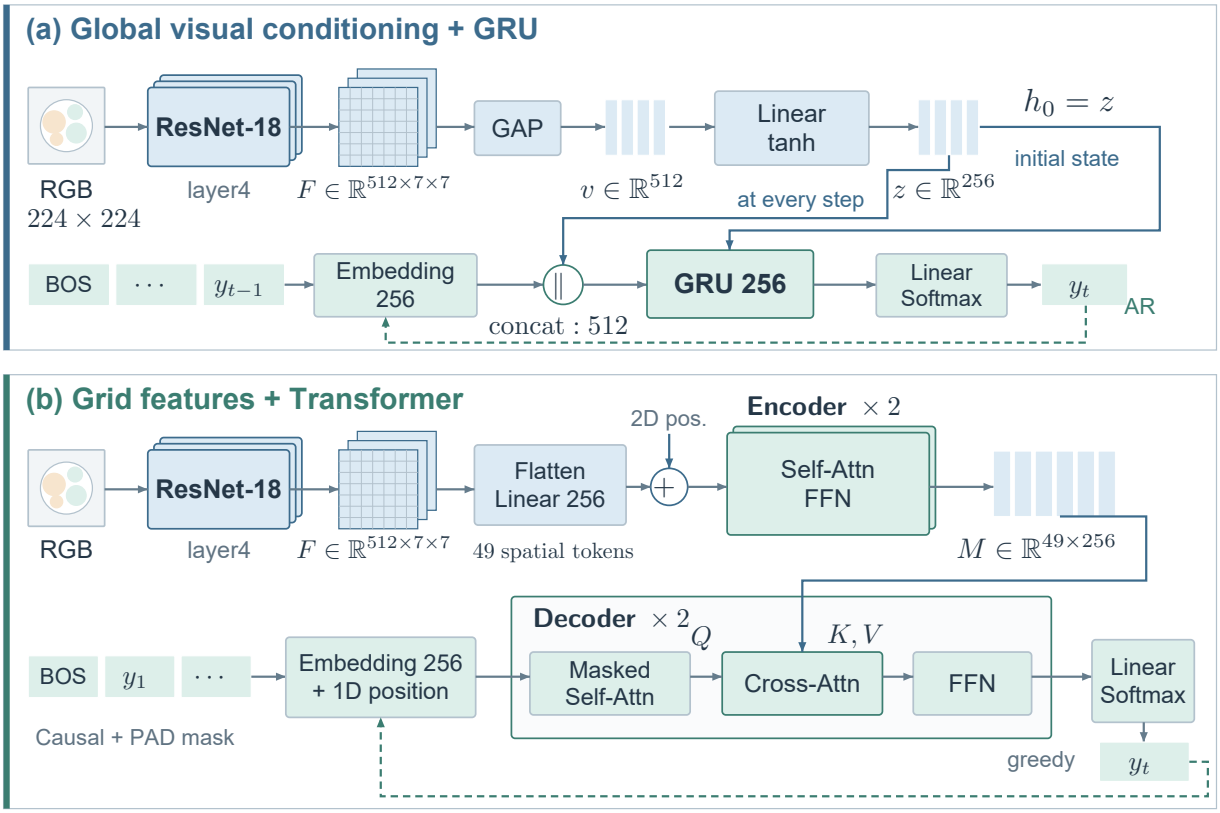


图 7 任务一双模型内部结构。A 以全局条件驱动循环生成；B 保留 49 个空间位置，通过视觉自注意力及解码交叉注意力读取图像。训练输入为右移真实序列，推理输入为已生成前缀。

模型 B：网格视觉与 Transformer。将 F 展平为 49×512，逐位置线性映射到 $d = 256$，加上二维行列正弦位置编码，再由两层 Transformer Encoder 输出视觉记忆 $M \in \mathbb{R}^{49\times256}$。Decoder 初设两层、4 个注意力头、前馈维度 1024、Dropout 0.1，文本嵌入加一维位置编

[1]骨干输出位置与预处理依据 Torchvision ResNet-18 文档及其源码。

码。每层先执行因果自注意力，再以文本状态为 Query、M 为 Key/Value 执行交叉注意力；每头维度为 64。固定大小网格无需视觉 Padding Mask，文本 Padding Mask 排除补齐位置；上三角因果掩码屏蔽未来 Token。该结构借鉴网格关系建模思路 [4]，不引入伪区域或多层网状连接。

训练与解码。Teacher Forcing 输入 $[\mathrm{BOS}, y_1, \ldots, y_{T-1}]$，目标为 $[y_1, \ldots, y_{T-1}, \mathrm{EOS}]$；交叉熵按全批非 PAD 目标数归一化，EOS 参与损失。先冻结骨干并保持 BatchNorm 为评价模式，训练投影与解码器；收敛后视验证结果以较小学习率解冻 `layer4`。主对照统一采用贪心生成，遇 EOS 或长度上限终止，束搜索仅作同协议补充。A 与 B 同时改变视觉表示和解码器，另设 B-Global：保留 B 的编码、解码配置，以投影全局向量形成单个视觉 Token，用一次轻量消融分析空间信息贡献。

5.3 结构化膳食记录生成

5.3.1 自主混合预测架构与参数迁移

任务二采用**共享视觉编码、食材序列生成、边界位置重量回归和整餐数值回归**的多任务结构，如图 8。从任务一 A 的最优监督 Checkpoint 迁移 ResNet-18、W_v, b_v 和 GRU；新增重量与营养回归头。食材序列使用与任务一相同的词级切分规则，在原词表后追加任务二训练集词语和边界 Token `SEP`，按 Token 字符串复制已有嵌入和输出层行，新行随机初始化。保留原词表 ID，验证集和测试集不参与扩词。这样既保留语言参数，也明确迁移范围。

食材列表序列化。名称先执行 Unicode 规范化、小写化与空白合并，不做基于测试标签的同义词扩展。同一记录中相同规范化名称合并并累加重量，再按名称字典序排序，得到 K 项 $\{(n_k, w_k)\}_{k=1}^{K}$。监督序列为

$$S = [\mathrm{BOS}, \mathrm{tok}(n_1), \mathrm{SEP}, \ldots, \mathrm{tok}(n_K), \mathrm{SEP}, \mathrm{EOS}]. \tag{3}$$

每个名称可占多个词，SEP 标识完整名称结束，排序规则减少同一集合多种排列带来的监督歧义。食材分支仍按式 (2) 逐词生成；不以训练食材全名白名单约束解码，以允许已知词组成新名称。全新词映射至 UNK，含 UNK 的项记为识别失败；即便后续改用子词编码，开放名称的可表示性也需与视觉识别准确性分别验证。

5.3.2 食材边界对齐与多任务训练

逐食材重量。定义 b_k 为目标 SEP 在预测序列中的时间步，h_{b_k} 表示*产生该 SEP 的 logits 所用状态*。Teacher Forcing 时该状态已读取完整的第 k 个真实名称；批处理额外保存 b_k、w_k 与有效项掩码，按位置 Gather 隐藏状态，不对 PAD 或普通词位置计算重量损失。推理每产生一个 SEP，便从同一位置提取状态并回归一项重量，输出项数由生成边界动态决定：

$$\widehat{w}_k = \mathrm{softplus}(f_w([h_{b_k}; z])), \qquad \widehat{\boldsymbol{q}} = \mathrm{softplus}(f_q([v; z])) \in \mathbb{R}^5_{\geq 0}. \tag{4}$$

两个 f 为独立的两层 MLP，隐藏维度初设为 256。$\boldsymbol{q}$ 按固定顺序表示总重量、总热量、蛋白质、脂肪和碳水化合物，分别以 g、kcal、g、g、g 为单位。输出经 Softplus 保证非负，整餐头不依赖生成的食材前缀，避免名称错误直接阻断全部数值输出。

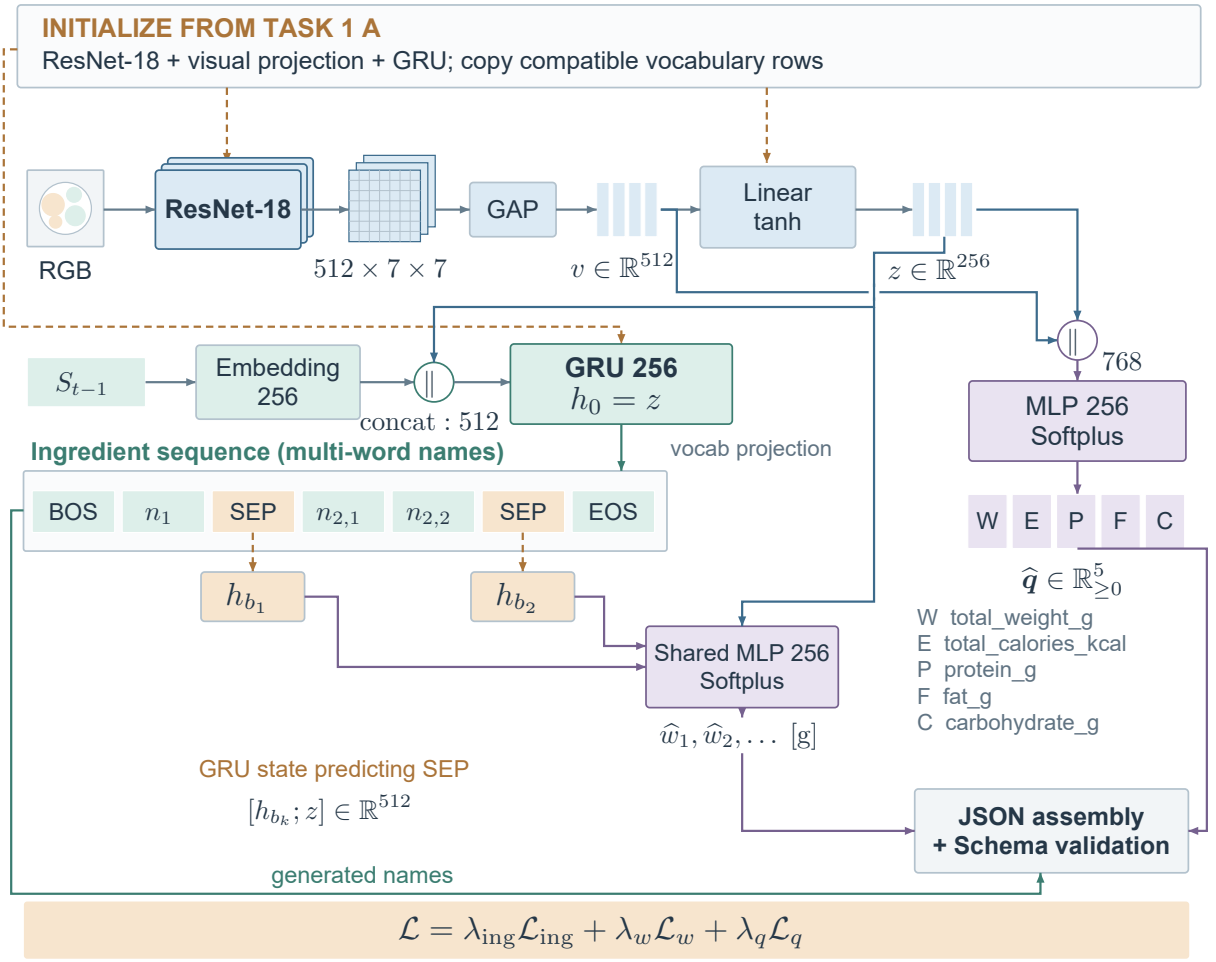


图 8 任务二自主混合架构。第 k 个 SEP 的预测状态 h_{b_k} 来自产生该 SEP logits 的 GRU 隐藏状态，虚线按边界位置选取；整餐五维数值由独立分支预测。虚线为迁移或监督，推理时沿实线动态组装记录。

尺度与联合目标。以训练集估计逐项重量及每个整餐字段的均值 μ_j、标准差 s_j，将 s_j 下限设为 10^{-6}。模型先输出原单位非负值，再以 $\mathcal{N}_j(a) = (a - \mu_j)/s_j$ 同时变换预测和标签，计算尺度一致的 Smooth L1（阈值 1）：

$$\mathcal{L}_{\text{ing}} = -\frac{1}{N_{\text{tok}}} \sum_{i,t} m_{it} \log p_\theta(S_{it} \mid S_{i,<t}, I_i),$$

$$\mathcal{L}_w = \frac{1}{N_{\text{item}}} \sum_{i,k} a_{ik} \ell\big(\mathcal{N}_w(\widehat{w}_{ik}), \mathcal{N}_w(w_{ik})\big),$$

$$\mathcal{L}_q = \frac{1}{5B} \sum_{i=1}^{B} \sum_{j=1}^{5} \ell\big(\mathcal{N}_j(\widehat{q}_{ij}), \mathcal{N}_j(q_{ij})\big),$$

$$\mathcal{L} = \lambda_{\text{ing}} \mathcal{L}_{\text{ing}} + \lambda_w \mathcal{L}_w + \lambda_q \mathcal{L}_q. \tag{5}$$

其中 m_{it} 排除 PAD，a_{ik} 标识真实食材，N_{tok}、N_{item} 为相应有效数，B 为批大小；无有效项时重量损失置零。三个权重先取 1，观察各损失及梯度量级，仅在验证集上小范围调整。训练先冻结视觉骨干联合学习新任务，再按需解冻末级视觉层。重量监督使用真实名称条件，最终评价使用自由生成结果，二者差异作为误差传播分析的一部分。

JSON 组装。推理限制首项非空、SEP 前至少有一个名称词、EOS 只出现在列表边界；达到长度或项数上限时丢弃未闭合末项并记录截断。空名、UNK 和非有限重量进入失败记录；有效重复名称按名称合并、重量求和。输出根对象含 `items` 及五个数值字段，项对象仅含 `name`、`weight_g`；验证字段集合、非空字符串、数值类型、有限性与非负性，拒绝布尔值和额外字段。组装时统一保留一位小数，数值评价使用同一交付值。依据已有审计，食材重量之和与整餐重量分别学习，**不设置二者相等的约束**。原始输出、清理日志与最终 JSON 同时留存，便于区分生成和后处理收益。

5.3.3 Qwen3-VL 的领域参数高效适配

预训练路线采用 **Qwen3-VL-4B-Instruct**，使用其官方 Processor 和 Chat Template 组织图像与对话[2]。每个样本的 user 消息包含 RGB 图像、固定膳食记录指令、字段与单位说明；assistant 消息为统一序列化的目标 JSON。仅 assistant 目标及其结束标记参与自回归交叉熵，系统提示、user 内容、图像占位和 PAD 的标签置为忽略值。训练前在单样本上逐段检查掩码，保留多模态控制 Token，序列超限时先控制图像 Token 与长度，不截断监督 JSON。

适配与资源控制。初始冻结视觉编码器、视觉语言映射及语言基础权重，在语言模型注意力的 Q/K/V/O 线性投影中注入 LoRA[9]，初设 $r = 8$、$\alpha = 16$、Dropout 0.05。依据模型实际模块路径限定注入范围，并输出可训练参数清单，避免同名视觉层被误选。先做小批量显存试跑：常规 BF16 LoRA 能容纳目标序列则优先采用；空间不足且算子兼容时，采用 NF4 4-bit、双重量化的 QLoRA[10]，冻结量化权重，以 BF16 或硬件支持的计算精度训练适配器。配合梯度累积、梯度检查点和图像分辨率上限控制开销，保持任务目标不变。

主实验比较同一 4B revision 的原始 Instruct、领域微调版本及自主混合模型；若 24 GB 单卡环境无法稳定运行，成对切换到同一 2B 基础模型重新比较，单独报告规模。图像预处理、固定指令、最大输出长度及贪心解码在适配前后保持一致。生成文本先严格解析再校验 Schema，主指标不做提示重试或内容修复；失败样本进入全样本统计。保存原始字符串、错误类型与成功解析值；如附加格式修复实验，单列其结果。模型、适配器、Processor、量化配置和解码配置共同构成可复现的推理版本。

5.4 训练优化与多模态评价

5.4.1 从监督训练衔接 SCST

任选优化优先用于任务一模型 A。先按验证集 CIDEr-D 选定交叉熵训练 Checkpoint，再复制该权重进入低学习率 SCST 阶段 [11]。对同一训练图像，生成采样序列 $y^s \sim p_\theta$ 和贪心序列 y^g，使用训练参考描述计算 CIDEr-D 奖励 r：

$$\mathcal{L}_{\mathrm{SCST}} = -\operatorname{stopgrad}\big[r(y^s) - r(y^g)\big] \sum_{t \le T_s} \log p_\theta(y_t^s \mid y_{<t}^s, I). \tag{6}$$

EOS 参与概率和，EOS 后的 PAD 不参与；采样与贪心分支采用一致的模型模式和最大长度，基线与奖励不反向传播。CIDEr-D 文档频率仅由训练参考预计算并固定，避免随

[2]输入格式及微调入口参考官方模型卡与 Qwen3-VL 官方仓库，实施时固定版本与模型 revision。

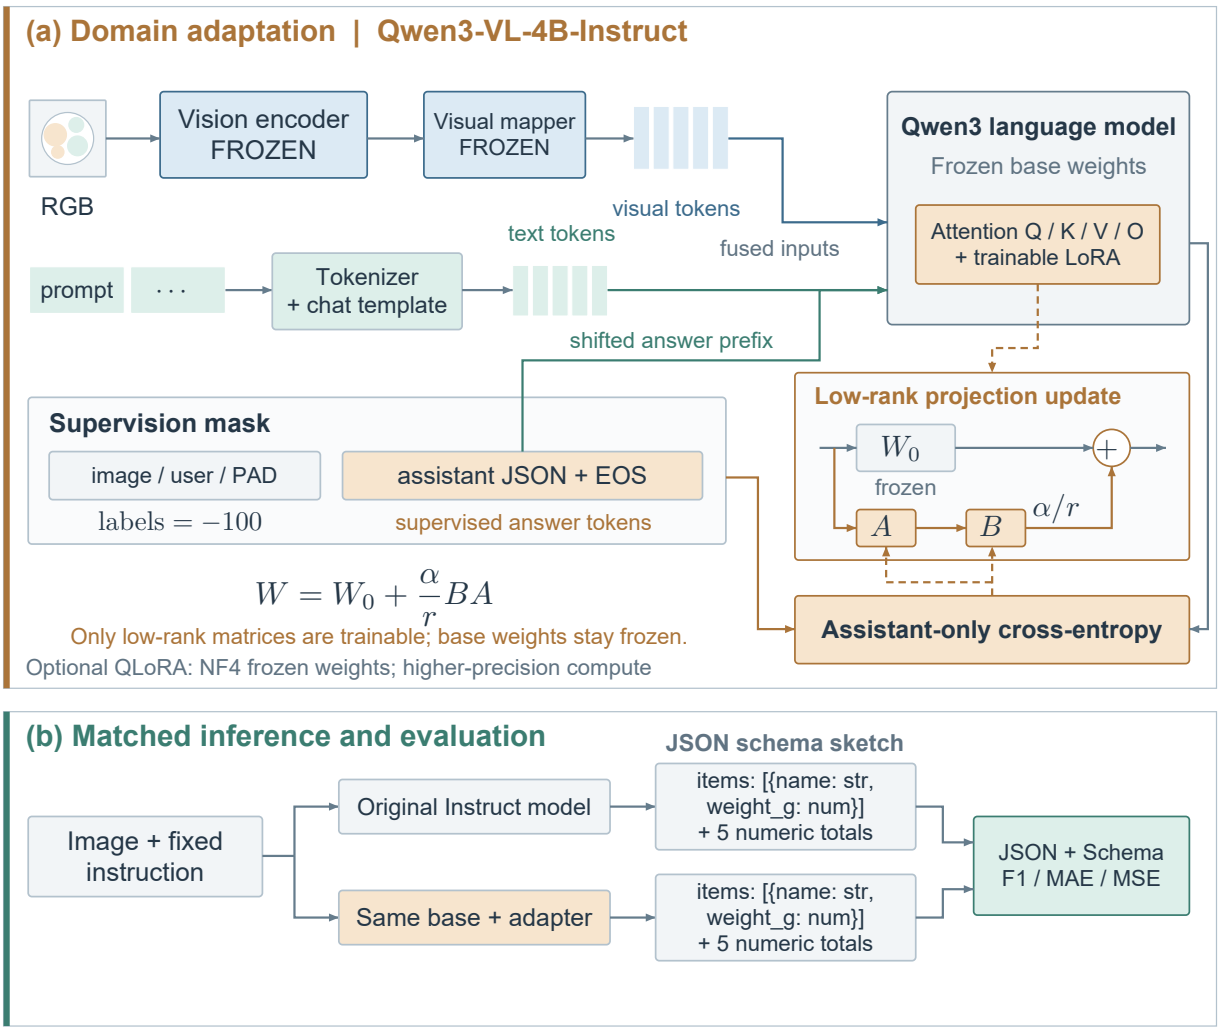


图 9 Qwen3-VL 领域适配流程。仅目标回答参与监督；同一基础模型在相同输入、生成和评价协议下比较适配前后差异。量化为可选存储策略，视觉部分初始冻结。

小批次改变奖励标尺。训练初期可使用 $\mathcal{L}_{\text{mix}} = (1-\eta)\mathcal{L}_{\text{CE}} + \eta\mathcal{L}_{\text{SCST}}$，$\eta$ 初设 0.5，再由验证稳定性决定是否调整。

最小交付为同一 A 模型监督训练前后两个版本、完全一致的测试解码与四项文本指标，并保存逐样本奖励及典型描述。除 CIDEr-D 外，同时检查 BLEU-4、METEOR、ROUGE-L 和食材幻觉，分析优化目标提升是否伴随细节与可读性的改变。若预算允许，增加相同步数继续交叉熵的对照，以区分额外训练与奖励优化的作用。

5.4.2 固定协议的 VLM-as-Judge 与人评对照

评价借鉴 CLIPScore 的图文相容性 [12] 以及 FLEUR、EXPERT 的视觉条件评分和解释组织 [13, 14]。使用冻结的原始 Instruct VLM 作 Judge，独立于领域微调权重；输入仅为图像、候选 Caption 和固定评分标准，隐藏模型名称及参考描述。四维均采用 1–5 分，语义正确性检查主要菜品与关系，细节覆盖检查可见属性，事实可靠性以高分表示少幻觉与错误食材，语言流畅度检查语法及自然程度。每维同时输出一句图像证据，固定模型 revision、提示模板、温度 0 与解析规则，解析失败率另行报告。

初始从测试集固定抽取约 60 张图像，覆盖菜品类别、长短描述与困难样本；在查看模型结果前锁定样本 ID。比较 A、B、A+SCST 的同图输出，以随机顺序、匿名方式交给

两名组员独立评分，少量分歧样本由第三名组员讨论裁定。用 Spearman 相关衡量 Judge、传统指标与人工均分的一致性，按图像进行 Bootstrap 给出区间，另报两名人评的加权 Cohen κ。人工样本较少时以维度趋势和错误案例为主；Judge 使用固定评分协议，不训练专门评价模型。记录同系列模型可能带来的偏好，并保留与人评不一致的原始解释供复核。

5.5 数据处理与实验设计

Food-500 Cap 的可靠映射与划分。官方说明将数据分为 19,760 条训练和 4,940 条测试图文对 [5]；本地标注文件实际为 19,880 和 4,940 条，须记录这一版本差异。本地图片来自社区镜像，先以官方 `filename`、类别与镜像索引建立显式映射，以官方 Caption 为文本依据；无法唯一确认的映射排除并记录，图像解码失败单列。复用已有审计结论处理少量缺失、映射差异及重复图像，固定文件 SHA-256、数据源 revision、排除原因和最终样本清单，不凭行号直接拼接图文。

对于跨官方训练/测试的相同图像组，测试归属优先，移除训练侧副本；同一测试重复组仅保留稳定排序后的一个代表。近重复组复核后采用相同策略。再按重复组从剩余官方训练集划出约 10% 验证样本，以类别分层尽量保持分布，种子设为 42；组内样本不跨划分。清洗后的计数以 manifest 为准，与原始数量分别报告。词表、长度统计及 SCST 奖励统计均仅从最终训练集拟合。

结构化数据与输入隔离。本地 `nutrition5k-student-v1` 包含 Train 2,338、Validation 414、Test 506，共 3,258 条，保留学校原始划分。数据加载器将 `image` 与 `target` 分开返回，推理接口只允许图像及固定指令，禁止传入 `target_text` 和含答案的 `metadata`。已有审计发现可变项数、训练未见食材、总量不一致及少量疑似同餐跨划分，故主结果沿用原划分，并在已标记疑似组上附分层敏感性分析。所有阈值、规范化映射与模型选择均在训练/验证阶段确定，测试集仅用于冻结方案后的最终评价。

表 3 统一评价协议与失败样本计入方式

对象	主要指标与统计单位	协议要点
Caption	BLEU-4、METEOR、ROUGE-L、CIDEr-D；语料级得分	同一 Tokenizer、单参考、实现版本与缩放单位
食材名称	Micro F1 为主，Macro F1 为辅；见过/未见名称分层	规范化全名精确匹配，预测无效项计 FP
食材重量	匹配项 MAE/MSE；全名称并集 MAE/MSE	漏检与多检按另一侧重量为零计入
整餐五维	各字段原单位 MAE、MSE，逐字段报告	解析失败采用预先规定的零预测计误差
输出结构	JSON 语法合法率、Schema 有效率	分母均为全部样本；额外报告截断/失败率

名称匹配与重量误差。真实和预测项采用同一名称规范化及重复项合并。按全名精确匹配，不用重量进行匹配，避免利用数值标签挑选最有利配对。令 U_i 为两侧名称并集，缺失侧重量置零，定义

$$E^{(p)}_{\text{union}} = \frac{\sum_i \sum_{n \in U_i} |\widehat{w}_i(n) - w_i(n)|^p}{\sum_i |U_i|}, \qquad p = 1, 2. \tag{7}$$

式 (7) 分别为并集 MAE 和 MSE，同时惩罚漏检和多检。匹配项误差单列，并给出匹配覆盖率；无匹配项记为不可计算，不记为零误差。非法名称项保留为互不匹配的预测项，计 FP 及其可读重量误差；完全无法解析的输出视作空食材集合、整餐零预测，仍保留在全样本分母中。另报有效输出子集误差与覆盖率，解释零预测约定的影响。对未见名称分别统计全名与组成词是否在训练集出现。辅助文本指标可用于规范化食材序列或 JSON，但不替代名称、重量及结构评价。

表 4 按实施优先级组织的最小实验矩阵

层次	实验组	主要问题
必选一	A、B；共享划分与贪心解码	全局循环与网格注意力两条路线的总体差异
必选二	自主混合；同规模原始/微调 Qwen	食材、定量与结构质量的领域适配收益
轻量消融	B-Global；混合模型仅视觉迁移 vs. 视觉 +GRU 迁移	空间信息贡献、序列迁移是否有效
任选	A 的 CE vs. SCST；Judge 与双人人评	奖励优化收益、评分一致性与幻觉变化

主对照固定清洗版本、训练预算与选择规则，记录参数量、可训练参数、单图推理耗时和实际显存。自主模型在预算允许时使用三个种子，报告均值与标准差；VLM 优先完成一个固定种子的配对适配实验，明确重复次数。任务一按验证 CIDEr-D 选模型；任务二按验证 Micro F1 选模型，接近时比较五维标准化 MAE，再比较有效率，规则在测试前固定。误差分析覆盖可见/隐含食材、长列表、未见名称、大份量、疑似同餐样本及重度质量不守恒样本，不将这些标记作为推理输入。

5.6 工程实现与可行性分析

采用 PyTorch 与 Torchvision，自主编写条件生成、掩码、损失、解码、边界对齐与记录组装；Transformer 可复用标准层，VLM 使用 Transformers、PEFT 和兼容的量化后端。工程拆分为数据与 manifest、Tokenizer、视觉骨干、序列解码器、回归头、训练器、解码器、Schema 与指标模块。训练接口接收图像及监督，返回分项损失；推理接口只接收图像和配置，返回逐样本预测及状态。先用 CPU 小样本验证尺寸、因果掩码、边界 Gather、梯度流、非负输出与 JSON 往返，再进入 GPU 训练。

配置统一保存种子、数据哈希、词表、数值统计、模型维度和生成参数；Checkpoint 保存模型、优化器、调度器、随机数状态及版本信息。自主模型初设 AdamW、学习率 3×10^{-4}、梯度裁剪 1.0；视觉层解冻后使用主学习率的十分之一，采用验证早停。总算力预算约 300 元，计划单卡 24 GB，先完成两项必选任务及同规模微调对照，再复用已有模型开展任选实验。GPU 型号、LoRA/QLoRA 最终配置、批量与步数由小样本试跑和预算共同确定，不预设训练时长或峰值显存。

主要风险集中在 RGB 份量歧义、小数据过拟合、食材序列训练与自由生成的差异，以及多模态量化兼容性。通过冻结骨干、验证早停、全样本指标和输出追踪控制风险；主混合分支若难以收敛，回退到共享 ResNet 的多标签食材预测加数值回归，并保留回退原因。优先交付可复现的完整推理与评价链路，再增加网格交叉注意力等局部增强。上述设计为待实施方案，模型效果及资源数据均由后续实验给出。

参考文献

[1] O. Vinyals, A. Toshev, S. Bengio, et al. Show and Tell: A neural image caption generator. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3156–3164, 2015. URL https://arxiv.org/abs/1411.4555v2.

[2] K. Xu, J. L. Ba, R. Kiros, et al. Show, Attend and Tell: Neural image caption generation with visual attention. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 2048–2057, 2015. URL https://proceedings.mlr.press/v37/xuc15.html.

[3] M. Cornia, M. Stefanini, L. Baraldi, et al. Meshed-Memory Transformer for image captioning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10578–10587, 2020. URL https://arxiv.org/abs/1912.08226.

[4] P. Zeng, H. Zhang, J. Song, et al. S^2 Transformer for image captioning. In *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence (IJCAI-22)*, pages 1608–1614, 2022. doi: 10.24963/ijcai.2022/224. URL https://www.ijcai.org/proceedings/2022/224.

[5] Z. Ma, M. Pan, W. Wu, et al. Food-500 Cap: A fine-grained food caption benchmark for evaluating vision-language models. In *Proceedings of the 31st ACM International Conference on Multimedia*, pages 5674–5685, 2023. doi: 10.1145/3581783.3611994. URL https://arxiv.org/abs/2308.03151v1.

[6] A. Salvador, M. Drozdzal, X. Giró-i-Nieto, et al. Inverse Cooking: Recipe generation from food images. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10453–10462, 2019. URL https://arxiv.org/abs/1812.06164v2.

[7] Q. Thames, A. Karpur, W. Norris, et al. Nutrition5k: Towards automatic nutritional understanding of generic food. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8903–8911, 2021. URL https://arxiv.org/abs/2103.03375.

[8] S. Bai, Y. Cai, R. Chen, et al. Qwen3-VL Technical Report. arXiv:2511.21631v2, 2025. URL https://arxiv.org/abs/2511.21631v2. Qwen Team; v2, 27 November 2025.

[9] E. J. Hu, Y. Shen, P. Wallis, et al. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022. URL https://openreview.net/forum?id=nZeVKeeFYf9.

[10] T. Dettmers, A. Pagnoni, A. Holtzman, et al. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*, volume 36, 2023. doi: 10.52202/075280-0441. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract.html.

[11] S. J. Rennie, E. Marcheret, Y. Mroueh, et al. Self-Critical Sequence Training for image captioning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 7008–7024, 2017. URL https://openaccess.thecvf.com/content_cvpr_2017/html/Rennie_Self-Critical_Sequence_Training_CVPR_2017_paper.html.

[12] J. Hessel, A. Holtzman, M. Forbes, et al. CLIPScore: A reference-free evaluation metric for image captioning. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 7514–7528, 2021. doi: 10.18653/v1/2021.emnlp-main.595. URL https://aclanthology.org/2021.emnlp-main.595/.

[13] Y. Lee, I. Park, and M. Kang. FLEUR: An explainable reference-free evaluation metric for image captioning using a large multimodal model. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 3732–3746, 2024. doi: 10.18653/v1/2024.acl-long.205. URL https://aclanthology.org/2024.acl-long.205/.

[14] H. Kim, S. Kim, J. Jeong, et al. EXPERT: An explainable image captioning evaluation metric with structured explanations. In *Findings of the Association for Computational Linguistics: ACL 2025*, pages 26642–26657, 2025. doi: 10.18653/v1/2025.findings-acl.1367. URL https://aclanthology.org/2025.findings-acl.1367/.