相关工作调研建议

~~我们的项目实际上涉及四个研究方向：~~

1. ~~食物图像描述生成：支撑 ResNet+GRU、ResNet+Transformer 两种自主模型。~~
2. ~~食物理解与营养估计：支撑任务三的食材识别、重量及营养预测。~~
3. ~~多模态预训练与参数高效微调：支撑 Qwen3-VL+LoRA。~~
4. ~~生成模型的训练优化与评价：支撑 SCST 和 VLM-as-Judge。~~

2. 我建议采用你提出的四部分结构

章节	调研重点	代表性论文
A. 食物图像理解领域研究进展	食物图像理解的研究现状、数据集、领域难点、现有方法的能力边界	Food-500 Cap、Nutrition5k、Inverse Cooking
B. 任务一：图像描述生成	CNN-RNN、视觉注意力、Transformer，重点论证模型 A/B 选型	Show and Tell、Show Attend and Tell、S^2 Transformer、M^2 Transformer
C. 任务二：结构化膳食记录生成	食材识别、重量及营养估计、结构化生成、VLM 微调	Inverse Cooking、Nutrition5k、Qwen3-VL、LoRA、QLoRA
D. 任选任务：优化与评价	SCST 强化学习、传统指标的局限、VLM-as-Judge	SCST、CLIPScore、FLEUR、EXPERT

一、首先必须读的 3 篇论文（了解任务的现状）

这三篇直接决定你们对 FoodLens 的任务理解和技术路线。

Food-500 Cap: A Fine-Grained Food Caption Benchmark for Evaluating Vision-Language Models

Ma et al. · ACM MM 2023

这是任务一数据集的原始研究论文。论文包含 24,700 张图像、494 个食物类别，并强调食材、形状、颜色等细粒度属性。

重点研究： 数据集如何构建、描述标注有什么特点、为什么通用 VLM 在食物领域仍存在识别困难。

直接服务于开题报告的“任务背景、数据集与研究动机”。

Inverse Cooking: Recipe Generation from Food Images

Salvador et al. · CVPR 2019

这篇论文研究从食物图像预测食材集合，并进一步生成烹饪步骤。它不仅考虑单个食材是否存在，还研究食材之间的依赖关系。

重点研究： 食材集合预测如何建模？为什么食材识别与自然语言生成可以分开处理？

对你们路线 C 的“食材预测 + 结构化生成”非常有参考价值，但它本身并不解决食材重量回归问题。

Nutrition5k: Towards Automatic Nutritional Understanding of Generic Food

Thames et al. · CVPR 2021

这是非常贴近你们任务二的研究。Nutrition5k 包含食物图像、食材重量和营养成分等标注，并研究如何通过视觉特征预测热量及宏量营养素。

重点研究： 重量、热量和营养值如何建模？如何进行多目标回归？RGB 图片估计营养信息有哪些局限？

直接支撑任务二数值预测方案的设计。

这三篇的重要性，我甚至认为高于某些传统深度学习基础论文。因为它们最直接地说明了你们到底要解决什么问题，以及前人已经解决到了什么程度。

二、成员甲：任务一图像描述与 SCST（6 篇）

这一方向的综述建议按 CNN-RNN → 视觉注意力 → Transformer → 细粒度食物描述 → 强化学习优化的逻辑展开。

论文	与 FoodLens 的关系	阅读重
④ Show and Tell（CVPR 2015）	模型 A 的经典基础	CNN-RNN 编解码、序列似
⑤ Show, Attend and Tell（ICML 2015）	从全局特征过渡到空间注意力	Attention 如何选择图像区
⑥ S^2 Transformer for Image Captioning（IJCAI 2022）	与模型 B 的网格特征路线高度相关	Grid Features、空间信息、
⑦ Meshed-Memory Transformer for Image Captioning（CVPR 2020）	图像描述 Transformer 的代表性工作	多层视觉特征建模、跨模态

其中我特别推荐成员甲重点研究 S^2 Transformer。它明确涉及网格特征与 Transformer 图像描述，与我们选定的 ResNet Grid + Transformer 更接近。

Meshed-Memory Transformer 则是理解高级 Transformer Captioning 架构的参考，但我们没有必要复刻它的记忆机制和网格状解码连接。

成员甲最终需要回答的核心问题是：

> 为什么我们选择“ResNet-18 + GRU”和“ResNet Grid + Transformer”作为两种自主模型？前人在图像表示、文本解码与训练优化方面已经做到了什么？我们的对比实验应该如何设计？

三、成员乙：任务二结构化膳食记录与 VLM（6 篇）

这一方向比任务一更需要深入调研，因为目前路线 C 的具体实现仍存在选择空间。

建议按 食材识别 → 重量与营养回归 → 多模态预训练 → 参数高效微调 → 生成结果评价 的顺序展开。

论文	与 FoodLens 的关系	
② Inverse Cooking（CVPR 2019）	路线 C：食材识别	食材集合预测、依
③ Nutrition5k（CVPR 2021）	路线 C：数值回归	RGB 输入、重量、
⑨ Qwen3-VL Technical Report（2025）	路线 D 的模型选型依据	视觉编码、多模态
⑩ LoRA: Low-Rank Adaptation of Large Language Models（ICLR 2022）	路线 D 的微调基础	低秩适配、冻结主
⑪ QLoRA: Efficient Finetuning of Quantized LLMs（NeurIPS 2023）	AutoDL 显存受限时的方案依据	4-bit 量化、低显存

Qwen3-VL 技术报告明确介绍了 2B、4B、8B 等多个 Dense 模型规模，为你们初选 4B、保留 2B 备选提供了依据。

FLEUR 值得成员乙认真阅读。它不是让语言模型只比较两段文本，而是同时利用图像和候选描述进行评价，并给出评分解释。这与你们任选任务中关注的语义正确性、内容覆盖和幻觉判断直接相关。

这一组的核心研究问题是：

> 从单张食物图像预测食材、重量和营养信息，已有研究采用了哪些方法？对于我们只有约 2,300 条训练样本的情况，自主模型迁移和 Qwen3-VL 微调分别应该怎样实现？

这里尤其需要区分食材识别的准确率与数值估计的准确率。不能因为 JSON 格式正确，就认为营养预测已经准确。

四、任选任务：优化与评价

Self-Critical Sequence Training（2017）	SCST 强化学习优化
CLIPScore（2021）	图像与描述的语义匹配评价
FLEUR（2024）	基于多模态模型的图像描述评价
EXPERT（2025）	可解释、多维度的图像描述评价

其中 FLEUR 和 EXPERT 直接对应 VLM-as-Judge；CLIPScore 更适合作为补充对照指标。